

Лабораторна робота №4: Генерація мовлення на основі мовної моделі (GPT2-TTS)

1. Архітектура моделі

1.1 Аудіо-кодек: FocalCodec

Для токенизації аудіо використовується **FocalCodec** (lucadellalib/focalcodec_25hz) -нейронний аудіо-кодек, що перетворює безперервний аудіосигнал у послідовність дискретних токенів з частотою 25 Гц (25 токенів на секунду). ноутбук містить **1024 записи** (CODEBOOK_SIZE = 1024).

Основні параметри:

- Вхідна частота дискретизації: 16 000 Гц
- Токен-рейт: 25 Гц (1 секунда аудіо $\approx$ 25 токенів)
- Розмір ноутбуку: 1 024

1.2 Мовна модель: GPT2-TTS

Базова модель -**GPT-2** (124 М параметрів, gpt2). До неї додано два нові модулі:

Модуль	Розмір	Призначення
audio_emb	(1026, 768)	Ембединги аудіо-токенів + 2 спеціальних (<BOS_AUDIO>, <EOS_AUDIO>)
audio_head	(768, 1026)	Проекційна голова для передбачення наступного токена

Загальна кількість параметрів: **137 М** (всі тренуються).

Формат вхідної послідовності

[text tokens] - ->[BOS_AUDIO] - ->[audio tokens] - ->[EOS_AUDIO]

Текстові токени кодуються через стандартний wte ембедінг GPT-2, аудіо-токени -через audio_emb. Функція втрат (cross-entropy) обраховується **тільки на аудіо-частині** (мітки -100 для текстових позицій).

1.3 Конфігурація

```
@dataclass
class GPT2TTSTConfig:
    base_model: str = "gpt2"
    codebook_size: int = CODEBOOK_SIZE # 1024
    n_special_tokens: int = 2
    # bos_id = 1024, eos_id = 1025
```

2. Датасет та попередня обробка

LJ Speech 1.1 -одномовний (англійська) датасет читання вголос:

- 13 100 записів, ~24 години аудіо
- Розбивка: 90 % train / 10 % val (фіксований seed 42)

Попередня обробка включає:

1. Завантаження WAV-файлу та ресемплінг до 16 кГц
2. Батчеву токенизацію аудіо через `codec.sig_to_toks()` з урахуванням довжини
3. Токенизацію тексту через `GPT2TokenizerFast`
4. Збереження у кеш (`train.pt` / `val.pt`) для повторного використання

3. Метод навчання

3.1 Тренувальний пайплайн

Використовується **PyTorch Lightning** (`GPT2TTSLightningModule`):

Параметр	Значення
Оптимізатор	AdamW
Learning rate	3e-4

Планувальник CosineAnnealingLR

Epochs 3

Batch size 8

Accelerator CUDA (T4 GPU)

Функція втрат -**cross-entropy** по зміщених мітках (авторегресивне навчання).

3.2 Особливості реалізації

- Батчі вирівнюються по максимальній довжині у батчі; padding не враховується у loss
- Вага градієнтів не передається через кодек (він заморожений: `p.requires_grad_(False)`)
- Тренування виконувалось на Kaggle із GPU Tesla T4

4. Інференс та методи семплювання

Генерація відбувається авторегресивно: модель отримує текстові ембединги + BOS_AUDIO і крок за кроком передбачає наступний аудіо-токен.

Реалізовано три стратегії:

4.1 Greedy (жадібний)

На кожному кроці обирається токен з **найвищою** ймовірністю (`argmax`).
Детерміновано, але схильний до повторень і монотонної інтонації.

4.2 Top-k (`k=50`, `temperature=0.8`)

З логітів залишаються тільки **50 найімовірніших** токенів, решта обнуляються.
Семплювання з розподілу, пом'якшеного температурою 0.8.
Балансує між якістю та різноманітністю.

4.3 Nucleus / Top-p (`p=0.9`, `temperature=0.9`)

Залишається мінімальна кількість токенів, сукупна ймовірність яких ≥ 0.9 , і з них семплюється. Температура 0.9.
Найгнучкіший підхід, адаптується до форми розподілу.

5. Метрики

Використовуються метрики з роботи xTTS:

Метрика	Інструмент	Значення
CER (Character Error Rate)	OpenAI Whisper base (ASR)	Нижче = краще
UTMOS	UTMOSv2 (нейронна MOS-оцінка)	Вище = краще (1–5)
SECS (Speaker Embedding Cosine Similarity)	SpeechBrain ECAPA-VOXCELEB	Вище = краще (0–1)

6. Результати

6.1 Детальна таблиця (4 тексти × 3 стратегії)

Текст	Стратегія	CER ↓	UTMOS ↑	SECS ↑
The quick brown fox...	Greedy	0.705	1.960	0.317
The quick brown fox...	Top-k (k=50, t=0.8)	0.659	3.154	0.406
The quick brown fox...	Nucleus (p=0.9, t=0.9)	0.841	3.549	0.395
Speech synthesis...	Greedy	0.714	3.232	0.396
Speech synthesis...	Top-k (k=50, t=0.8)	0.762	3.736	0.375
Speech synthesis...	Nucleus (p=0.9, t=0.9)	0.762	3.086	0.176
Lightning strikes...	Greedy	0.787	2.963	0.372
Lightning strikes...	Top-k (k=50, t=0.8)	0.830	3.451	0.362
Lightning strikes...	Nucleus (p=0.9, t=0.9)	0.872	3.230	0.475
Scientists discovered...	Greedy	0.717	2.377	0.455
Scientists discovered...	Top-k (k=50, t=0.8)	0.736	2.639	0.279

Scientists discovered...	Nucleus (p=0.9, t=0.9)	0.774	2.730	0.368
-----------------------------	------------------------	-------	-------	-------

6.2 Середні метрики по стратегії

Стратегія	CER ↓	UTMOS ↑	SECS ↑
Greedy	0.731	2.633	0.385
Top-k (k=50, t=0.8)	0.747	3.245	0.356
Nucleus (p=0.9, t=0.9)	0.812	3.149	0.353

7. Аналіз результатів та гіпотези

CER

Greedy-семплювання дає **найнижчий CER (0.731)** -тобто найкращу розбірливість. Це очікувано: вибираючи завжди найімовірніший токен, модель відтворює найбільш «впевнені» фонemi. Nucleus-семплювання дає найгірший CER (0.812) через більшу стохастичність, що інколи призводить до фонетичних помилок чи артефактів.

UTMOS (суб'єктивна якість)

Top-k випереджає за UTMOS (3.245 vs 3.149 для nucleus і 2.633 для greedy). Greedy має **найнижчу** суб'єктивну якість -мова звучить монотонно та «роботизовано», що відображається у низьких MOS-оцінках. Стохастичні методи вносять варіативність інтонації, що сприймається як більш природна мова.

SECS (схожість голосу)

Greedy найкраще зберігає характеристики голосу (0.385). Це може бути пов'язано з тим, що детерміноване декодування тяжіє до «середнього» голосового профілю датасету (LJ Speech -одна дикторка), тоді як стохастичні методи вносять варіацію, яка відхиляється від еталонного ембедингу.

Загальні спостереження

- Значення CER загалом **дуже високі (>0.7)** для всіх стратегій, що свідчить про недостатнє навчання. 3 епохи на LJ Speech -занадто мало для GPT-2-based TTS; в

реальних системах навчають десятки епох або використовують більші batch size і learning rate scheduling.

- UTMOS у діапазоні 2–3.7 (при максимумі 5) вказує на розбірливе, але не природне мовлення.
- **Тор-к є найкращим компромісом:** прийнятний CER + найвищий UTMOS.

8. Висновки

	Найкраще
Розбірливість (CER ↓)	Greedy
Суб'єктивна якість (UTMOS ↑)	Top-k (k=50, t=0.8)
Схожість голосу (SECS ↑)	Greedy
Баланс усіх метрик	Top-k (k=50, t=0.8)

Реалізована система демонструє базову здатність до синтезу мовлення з тексту після лише 3 епох навчання. Для продакшн-якості необхідно: більше епох навчання, більший batch size, classifier-free guidance або beam search для покращення розбірливості, а також fine-tuning кодека під цільовий голос для покращення SECS.