

# Звіт з Лабораторної роботи №1

## Аудіо Машинне Навчання

Матвій Шумилович, Андрій Кравчук та Едвард Студент

17 березня 2026 р.

## 1 Завдання №1: Розпізнавання фонем на основі SSL моделей

### 1.1 Огляд даних, особливості та проблеми

Для виконання завдання побудови моделі розпізнавання фонем було використано набір даних TIMIT. Цей датасет містить анотації у вигляді 61 фонем, проте для порівнянності результатів зі стандартними протоколами оцінювання, ми реалізували відображення (mapping) цієї множини у зменшений набір із 39 фонем. Такий підхід дозволяє об'єднати фонем, які дуже схожі за звучанням, та звести різноманітні символи пауз і тиші до єдиного класу. Оскільки датасет TIMIT вже має офіційний розподіл на тренувальну (train) та тестову (test) вибірки, тестова вибірка залишалася недоторканою до моменту фінального оцінювання, а тренувальні дані ми розділили на навчальну та валідаційну вибірки (10% даних пішло на валідацію). Це дозволило об'єктивно слідкувати за перенавчанням моделі. Всі файли, що належать до одного запису (аудіо, транскрипція та послідовність фонем), об'єднувалися в єдину структуру для зручності завантаження під час тренування.

### 1.2 Опис використаних підходів

Основною ідеєю роботи було використання переднавчених моделей навчання без вчителя (Self-Supervised Learning — SSL) у якості екстракторів ознак (feature extractors). Ми протестували дві моделі: Wav2Vec2 ([facebook/wav2vec2-base-960h](https://github.com/facebookresearch/wav2vec2)) та HuBERT ([facebook/hubert-large](https://github.com/facebookresearch/hubert)). Замість використання лише останнього прихованого шару (last hidden state), ми проводили експерименти з ознаками з різних проміжних шарів (шари 0, 3, 6, 9, 12), адже різні рівні нейромережі можуть по-різному кодувати фонетичну інформацію. Для пришвидшення процесу навчання ці ознаки були одноразово пропущені через базову модель і збережені у кеш у вигляді тензорів.

Поверх цих SSL-ознак навчалися спеціалізовані "голови" (heads) для класифікації. Ми реалізували і порівняли три архітектури:

- **LinearHead**: звичайний повнозв'язний шар, який проводить лінійну класифікацію.
- **MLPHead**: багатошаровий перцептрон з одним прихованим шаром на 256 нейронів та функцією активації ReLU.
- **BiLSTMHead**: двонаправлена LSTM (2 шари, 256 прихованих нейронів), що дозволяє моделі аналізувати контекст як з минулого, так і з майбутнього аудіопотоку.

Оскільки тривалість аудіо та довжина цільової послідовності фонем є різними й динамічними, ми використовували функцію втрат CTC (Connectionist Temporal Classification). Програмний та математичний принцип її роботи полягає у тому, що вона підраховує ймовірність усіх можливих шляхів, які можуть призвести до правильної послідовності, шляхом додавання спеціального символу (blank) та об'єднання повторюваних фонем. Математично це виражається як функція мінімізації негативного логарифма правдоподібності цільової послідовності  $Y$  за умови вхідних ознак  $X$ :

$$\mathcal{L}_{CTC} = -\ln P(Y|X) = -\ln \sum_{\pi \in \mathcal{B}^{-1}(Y)} P(\pi|X) \quad (1)$$

де  $\pi$  — це один із можливих шляхів (вирівнювань) на рівні фреймів, а  $\mathcal{B}^{-1}(Y)$  — множина всіх шляхів, які після видалення порожніх символів (blank) та дублікатів зводяться до правильної цільової послідовності  $Y$ .

Після передбачення ймовірностей фонем для кожного фрейму, ми застосували алгоритм жадібного декодування (greedy CTC decode): на кожному кроці обирається найбільш ймовірний клас, після чого видаляються повтори підряд і символи "blank".

Для обчислення фінальної помилки використовувалася метрика PER (Phoneme Error Rate), яка рахує відстань Левенштейна (мінімальну кількість вставок, видалень та замінів) між еталонною та згенерованою послідовністю фонем, поділену на довжину еталонної послідовності.

### 1.3 Таблиці метрик та Гіпотези щодо результатів

У таблиці нижче наведено результати оцінки (Test PER) для найкращих комбінацій шарів та класифікаторів.

| SSL Модель | Класифікатор | Номер шару | Validation PER | Test PER     |
|------------|--------------|------------|----------------|--------------|
| HuBERT     | BiLSTM       | 9          | 0.096          | <b>0.098</b> |
| HuBERT     | Linear       | 9          | 0.115          | 0.115        |
| Wav2Vec2   | BiLSTM       | 9          | 0.100          | 0.100        |
| Wav2Vec2   | Linear       | 9          | 0.115          | 0.115        |

Табл. 1: Порівняння архітектур та обраних шарів (найкращі показники).

**Гіпотези й думки:** Отримані результати підтверджують гіпотезу, що не всі приховані шари є однаково корисними для розпізнавання фонем. Найкращий результат для обох моделей (HuBERT та Wav2Vec2) ми отримали саме на 9-му шарі, що свідчить про те, що фонетична інформація оптимально кодується на середніх та пізніх етапах трансформера, тоді як найостанніший шар може містити більше абстрактної, високорівневої або лінгвістичної інформації. Крім того, архітектура BiLSTM стабільно перевершувала Linear і MLP. Це логічно, адже фонемі сильно залежать від контексту звуків, які йдуть до і після них, а саме двонаправлена LSTM здатна врахувати ці часові залежності. В цілому, HuBERT показав дещо менший рівень помилок ( $PER \sim 0.098$ ), ніж Wav2Vec2.

## 2 Завдання №2: Аудіо фільтри для покращення якості даних

### 2.1 Опис запропонованих алгоритмів фільтрування

Для спроби покращити якість датасету ТІМІТ без застосування методів глибокого навчання, ми розробили та протестували три класичні методи цифрової обробки сигналів:

1. **Pre-emphasis (Пре-емфазис):** Цей фільтр використовується для збалансування спектру частот. Він підсилює високі частоти, які зазвичай мають меншу амплітуду у людському мовленні, порівняно з низькими частотами. Це було реалізовано за формулою  $y[t] = x[t] - \alpha \cdot x[t - 1]$ , де коефіцієнт  $\alpha = 0.97$ .
2. **Bandpass Filter (Смуговий фільтр Баттерворта):** Класичний частотний фільтр, який пропускає лише ті частоти, які є найбільш інформативними для людської мови. Ми застосували фільтр 4-го порядку із частотою зрізу від 300 Гц до 3400 Гц, усуваючи низькочастотний гул та високочастотний шум.
3. **Wiener Filter (Фільтр Вінера):** Алгоритм фільтрації, що базується на статистичному підході до мінімізації середньоквадратичного відхилення між бажаним (чистим) і наявним (зашумленим) сигналом. Цей фільтр був реалізований за допомогою бібліотеки `scipy.signal.wiener`.

### 2.2 Абляційне дослідження по впливу алгоритмів фільтрування

Щоб оцінити вплив кожного фільтра на кінцеву якість, ми провели абляційне дослідження. Фільтри послідовно застосовувалися до сирих аудіоданих, після чого аудіо передавалося на вхід найкращій моделі з першого завдання (HuBERT, 9 шар, класифікатор BiLSTM). Результати подані у таблиці нижче:

| Тип фільтру                   | Показник Test PER |
|-------------------------------|-------------------|
| Базова модель (без фільтрів)  | 0.0980            |
| Wiener Filter                 | 0.1007            |
| Pre-emphasis                  | 0.1011            |
| Bandpass Filter (300-3400 Hz) | 0.1019            |

Табл. 2: Абляційне дослідження впливу фільтрів на точність моделі HuBERT.

Як показують метрики, жоден із базових фільтрів не приніс покращення по PER. Більше того, їх застосування призвело до незначного збільшення помилок. Цьому є раціональне пояснення. По-перше, датасет ТІМІТ є професійним студійним записом, тому в ньому практично відсутній фоновий шум, і фільтрація, відсікаючи певні спектри частот, лише видаляє корисну акустичну інформацію. По-друге, сучасні SSL-моделі (такі як HuBERT) під час пре-тренування (pre-training) на великих об'ємах даних вже вчаться виділяти стійкі фонетичні ознаки та є дуже робастними до легкого шуму. Тому ручне відфільтровування сигналів для таких моделей виявляється неефективним і навіть шкідливим на чистих даних.

### 2.3 Інші об'єктивні метрики для оцінки якості даних

Для того, щоб об'єктивно оцінювати якість початкових та відфільтрованих даних, крім PER, варто було б запровадити наступні метрики:

- **SNR (Signal-to-Noise Ratio):** співвідношення сигнал/шум, яке фізично вимірює потужність чистого сигналу мовлення у порівнянні до потужності фонового шуму. Якщо фільтр справді усунув шум, метрика SNR повинна зрости.
- **PESQ (Perceptual Evaluation of Speech Quality):** стандартна метрика ITU-T, яка симулює людське сприйняття мовлення і дозволяє оцінити загальну якість звуку та його зрозумілість до і після фільтрації.